

语料库多维统计综合研究报告

作文语言特征与母语参照 综合分析

基于 620 篇 HSK 学习者作文与 180 篇公开网络高中作文的 MF/MD 研究

800 篇作文 · 301 列统计 · 39 项最终指标 · 5 个语言维度

2026 年 8 月

目录

章节	页码
摘要	3
1 研究背景与整合问题	4
2 数据来源与 800 篇样本	6
3 301 项语言特征与统计方法	9
4 学习者作文的五维结构	12
5 学习者四组、分数与国籍	16
6 公开网络母语参照样本审计	23
7 四组母语参照对照	26
8 稳健性与联合因子分析	33
9 五维综合证据	37
10 教学与研究启示	40
11 局限	40
12 结论	41
参考文献与网页来源	41
附录 A 最终因子载荷	43
附录 B 母语样本审计摘要	44
附录 C 可复现性说明	44

目录页码按最终渲染版本回填。

摘要

本报告把项目既有的学习者作文 MF/MD 分析和公开网络母语参照分析整合为一条连续证据链。学习者语料包括 J1、J2、Y1、Y2 四组各 155 篇，共 620 篇；母语参照包括 NJ1、NJ2、NY1、NY2 四组各 45 篇，共 180 篇。两类语料均经过相同的 PyNLPIR 分词与 301 列语言特征统计，总样本量为 800 篇。母语参照来自作文网高中作文栏目，可以证明网页栏目归类，但不能独立验证作者身份或排除编辑、转载和润色，因此全文统一使用“公开网络母语参照语料”这一审慎名称。

学习者分析从 146 项直接指标出发，经方差、稀疏性、相关性和 KMO 筛选，并使用 MinRes 提取、Promax 旋转、平行分析与 Bootstrap 稳定性检验，最终得到 5 个维度和 39 项指标。所选模型 KMO=0.752，累计解释方差为 57.3%。母语分析固定使用学习者样本的均值、标准差和载荷方向投影，避免用母语样本重新定义量尺。20 项题目配对维度比较中有 13 项经 Holm 校正后显著，18 项在 1000 次篇幅匹配重抽样中的 95% 区间不跨 0。

学习者内部分析显示，题目与体裁组合在五个维度上均存在结构性差异，1 个维度与作文分数呈校正后显著相关。母语参照进一步揭示，学习者与公开网络高中作文的差异不是单一的“高级或低级”，而是分布在词汇丰富度、基础词汇配置、人称指涉、句法延展和动作链等多个方向。联合 800 篇作文重新探索因子结构时，只有 2 因子方案同时通过诊断与稳定性检验，说明原五维结构适合作为固定比较量尺，但不能被视为跨来源完全不变的普遍结构。

核心结论

五维得分描述的是语言资源配置，不是作文质量排名。最可信的结论来自题目配对、效应量、稳健回归、篇幅重抽样和主题敏感性共同支持的方向；母语参照结果应解释为语料来源差异，而不是经过身份认证的母语能力因果效应。

关键词：HSK 作文；MF/MD；语言特征；母语参照；因子分析；词汇丰富度；句法复杂度

1 研究背景与整合问题

学习者作文研究经常依赖字数、词汇等级或单项语法指标，但这些指标彼此相关，单独解释容易把题目需求、篇幅和语言能力混为一谈。Biber 提出的多特征多维度方法强调先观察多项语言特征的共同变异，再以因子载荷解释潜在功能维度。徐勤 2021 年的叙述文研究和 2023 年博士论文把这一思路用于日本人汉语学习者与汉语母语者作文比较，为本项目提供了指标组织、斜交旋转和维度解释的直接方法参照。

本项目首先在 620 篇 HSK 作文内部建立五维量尺，回答不同题目、分数及补充国籍因素如何与语言资源配置相关。随后，项目从公开网络高中作文中构建 180 篇参照语料，并将其投影到完全相同的五维量尺。两阶段分析原本分别报告，容易造成方法说明重复，也不利于判断某个维度究竟是学习者内部差异、分数差异，还是学习者与参照语料之间的来源差异。本综合报告因此以同一组研究问题串联两阶段证据。

整合研究问题

RQ1：620 篇学习者作文呈现怎样的稳定多维结构？RQ2：J1、J2、Y1、Y2 在五维上有何差异？
RQ3：作文分数及日本籍控制变量与维度得分有何关系？RQ4：四组公开网络母语参照与对应学习者题目在五维和具体指标上有何差异？RQ5：这些差异能否经受篇幅、主题、年份和联合因子结构检验？

1.1 两阶段证据的关系

学习者阶段的五维模型是主量尺，母语参照阶段是外部投影。投影过程固定 39 项指标的标准化参数及载荷正负方向，因此母语样本不会反向改变原模型。这一设计优于把 800 篇作文直接混合后重新命名维度，因为后者无法区分原学习者结构和新增语料引起的结构变化。联合 EFA 只作为敏感性分析，专门检查这种变化。

1.2 解释边界

- J1/J2 与 Y1/Y2 同时包含题目和体裁差异，不能将组间差异解释为纯粹体裁效应。

- 公开网页高中作文不是身份、年龄和写作条件均可核验的实验母语语料，不能直接推出母语能力因果结论。
- 五维正负方向来自统计载荷，不表示好坏；维度得分高只表示相应语言资源更集中。
- 作文分数缺少 75 分层级，并且是既有评分结果；相关与回归分析不构成评分因果模型。

证据层级	回答问题	主要方法	解释边界
描述层	各组使用了哪些语言资源	均值、比例、每千字频率	不能说明差异是否稳定
学习者推断层	题目组和分数是否相关	Welch、效应量、Spearman、HC3	不能推出体裁或分数的因果效应
外部参照层	同题参照与学习者差在哪里	固定投影、Hedges g、Bootstrap	不能认证网页作者身份
稳健性层	结论是否依赖篇幅、主题或模型	重抽样、敏感性、联合 EFA	不能消除所有未观测混杂

表 0 综合报告的四层证据结构。

2 数据来源与 800 篇样本

2.1 学习者作文

学习者语料来自 HSK 动态作文语料库筛选结果。J1 为 人物影响记叙，J2 为 假期经历记叙，Y1 为 吸烟、健康与公共利益议论，Y2 为 父母教育与儿童成长议论。抽样在各分数层内保持四组数量一致，并尽量扩大国籍覆盖、平衡同一国籍数量；排除中国香港、中国台湾、中国澳门和中国少数民族样本。75 分样本已从主表移除，最终每组 155 篇。

篇名代码	篇名	体裁	样本量	平均分	平均纯文本字数	国籍数
J1	记对我影响最大的一个人	记叙文	155	75.645	390.503	18
J2	我的一个假期	记叙文	155	75.645	376.652	14
Y1	吸烟对个人健康和公众利益的影 响	议论文	155	75.645	357.665	29
Y2	父母是孩子的第一任老师	议论文	155	75.645	382.284	28

表 1 学习者作文样本结构。每组 155 篇，总计 620 篇。




图 1 学习者作文的样本、体裁与分数结构

2.2 公开网络母语参照作文

参照候选来自作文网高中作文栏目、高一至高三常规作文页面及高中作文文库。完整高中单元作文和练习来源作文可以纳入；仅有题目、要求、讲解或素材的练习页仍排除。另排除满分作文、

范文、写作指导、点评、解析、读后感、演讲稿、小说和诗歌。NY2 保留了初中作文最后备用通道，但最终 180 篇全部来自高中范围，未启用初中备选。

目标原为每组 50 篇。完成候选发现、正文提取、篇幅约束、体裁校验、正文哈希与字符五元组近重复去重后，NJ2 只有 45 篇合格候选，因此四组统一缩减为各 45 篇。主题匹配分为精确、近似、扩展和宽泛四级；为保持高中范围，NY1、NY2 及部分 NJ2 放宽到相邻题目域。这些宽泛主题提高了样本量，也降低了严格同题可比性。

母语代码	样本量	平均汉字数	精确主题	近似主题	扩展主题	宽泛主题	高一	高二	高三
NJ1	45	508.556	4	5	36	0	15	15	15
NJ2	45	579.444	4	4	3	34	12	7	12
NY1	45	627.822	2	0	1	42	13	19	13
NY2	45	528.444	3	1	10	31	15	14	16

表 2 母语参照样本的主题匹配和年级结构。




图 2 四组母语参照样本的主题匹配层级

2.3 文本处理与版权边界

两类语料都保留原文、清洗正文和 PyNLPIR 分词文本三个层次。学习者原文中的网站标注按可确定规则清理；母语网页正文仅删除标题、日期、来源、广告、二维码和版权尾注，不修改措辞或纠正错别字。所有全文目录与网页缓存均只保存在本地并通过 .gitignore 排除。公开仓库只保存来源元数据、派生统计和分析结果。本综合报告不列出 180 条来源 URL，也不展示完整网页作文。

语料命名

作文网把文章归入高中作文栏目，但栏目归类不能独立证明作者身份、写作年龄或是否经过编辑。本报告使用“公开网络母语参照语料”，避免把来源标签误写成实验事实。

维度	学习者作文	母语参照作文	剩余限制
题目	四个固定 HSK 题目	按四题建立对应主题域	部分母语组使用扩展或宽泛主题
体裁	J 组记叙、Y 组议论	对应组优先匹配记叙或议论	网站体裁标签可能不完全可靠
篇幅	约 358 至 391 字均值	按学习者分位点匹配	母语文本仍整体偏长
写作条件	语料库既有评分作文	公开网页文章	时间、修改和资料使用均不可比
身份信息	国籍可用	栏目和年级标签可用	网页作者身份不能独立核验
文本处理	标注清洗后分词	网页正文清理后分词	均使用相同 301 列统计口径

表 2-1 两类语料的可比条件与不可消除差异。

3 301 项语言特征与统计方法

3.1 特征体系

每篇作文的宽表共有 301 列，包括 8 列基本信息、5 列基础篇幅指标和 288 列派生语言特征。派生特征覆盖词汇丰富度、词汇密度与词长、句段结构、词性、语法标记、篇章连接、记叙描写和 HSK 词汇八类。次数型特征同时保存原始次数与每千汉字频率，统一分母为纯文本汉字数；比例、均值、TTR、Guiraud 和 MATTR 直接保存计算值。

类别	字段数	核心内容
基础篇幅	5	字数、纯文本字数、分词数、非标点分词数、去重词数
词汇丰富度	18	TTR、Guiraud、MATTR-50、仅出现一次词及词类 TTR
词汇密度与词长	21	内容词、实虚词、词汇密度、平均词长及单双多字词
句段结构	22	句段数、句长、长句、逗号、分句和段落长度
词性	46	23 类词性的次数与每千字频率
语法标记	56	代词、情态、否定、体标记、结构助词、介词和语气词
篇章连接	21	八类连接词及总量、去重数和多样性
记叙描写	26	时间、动作、心理、言说、趋向、评价、引语和动词链
HSK	78	数字等级、初中高、覆盖率、词种、TTR 及非 HSK 拆分

表 3 301 列宽表中的统计类别；另有 8 列基本信息。

HSK 词汇使用 11,000 条新版考试大纲词表，主等级 1 至 3 归为初等、4 至 6 归为中等、7 至 9 归为高等。词汇占比分母为全部非标点 token。同形词多等级时优先使用 PyNLPIR 词性匹配，仍无法唯一判断时归入最低主等级。非 HSK 词拆分为专名、数字、字母串和其他；“其他”不能直接解释为错误或高级词。

3.2 学习者五维模型

因子候选只使用每千字频率、比例、TTR、MATTR、Guiraud、均值和句长等可直接比较指标，排除原始次数、篇幅指标和确定性重复总量。依次剔除零方差、95%以上为零的稀疏变量、绝对相关不低于 0.85 的冗余变量及变量级 KMO 低于 0.50 的指标。候选模型使用 MinRes 提取和 Promax 斜交旋转，再以共同度、因子主要载荷数、Heywood 异常和 Bootstrap Tucker 一致性筛选。

筛选阶段	保留指标数
初始直接指标	146
方差与稀疏性后	141
相关性筛选后	115
变量级 KMO 筛选后	93
最终五维模型	39

表 4 学习者 MF/MD 指标筛选流程。完整逐项原因见分析结果工作簿。




图 3 从 301 列宽表到最终 39 项指标的筛选流程




图 4 平行分析、碎石图与候选模型比较

平行分析建议 14 个因子，但高维方案无法同时满足可解释性、每因子主要载荷数和稳定性要求。最终选定 5 因子、39 变量模型，KMO=0.752，样本变量比为 15.9，200 次 Bootstrap 的五个因子 Tucker 一致性中位数均高于 0.992。

3.3 推断统计与固定投影

- 学习者四组比较使用 Welch 方差分析、Holm 校正两两 Welch 检验、Omega 平方和 Hedges g。
- 分数关系同时使用 Spearman 相关与 HC3 稳健回归：维度得分 ~ 作文分数 + 篇名代码 + 是否日本籍。
- 母语参照使用学习者均值、标准差及载荷方向进行固定投影；学习者重新投影误差不超过 4.44×10^{-16} 。
- 四组母语对照报告 Welch 检验、Hedges g、Bootstrap 区间和 Holm 校正；39 项具体特征使用 BH 校正。
- 稳健性包括 1000 次篇幅最近邻重抽样、严格主题与优先年份子样本、控制 log 篇幅的 HC3 回归和 800 篇联合 EFA。

指标	公式	解释
每千汉字频率	特征次数 ÷ 纯文本字数 × 1000	控制文本长度的机械影响
TTR	去重词数 ÷ 非标点分词数	受文本长度影响的词形多样性
Guiraud	去重词数 ÷ $\sqrt{\text{非标点分词数}}$	对篇幅进行平方根修正
MATTR-50	连续 50 词窗口 TTR 的平均值	局部词汇丰富度；短文使用全文 TTR
HSK 等级占比	该等级 token 数 ÷ 非标点分词数	词汇等级构成而非能力分数
维度得分	正载荷指标 z 分之之和 - 负载荷指标 z 分之之和	再在学习者样本内标准化

表 4-1 核心指标及维度得分口径。

4 学习者作文的五维结构




图 5 最终 39 项指标的 Promax 旋转载荷

载荷阈值取绝对值 0.30。维度名称根据正负两端主要载荷及语言功能中性命名；斜交旋转允许维度相关，因此同一指标可能在多个维度上有次要载荷。下列解释使用主要载荷，而完整载荷矩阵见附录 A。

4.1 D1 词汇丰富度与词汇扩展

该维度集中反映词形多样性、篇内低重复程度以及名词和动词词库的扩展。高分表示同等篇幅内动用的不同词形较多，不等同于词语更生僻，也不能单独代表作文质量。

主要正载荷：词形丰富度 TTR (0.97) 、仅出现一次词占比 (0.84) 、MATTR-50 (0.80) 、动词 TTR (0.73) 、名词 TTR (0.72) 、动词去重词每千字 (0.71) 。

字段名	类别	主要载荷	共同度
词形丰富度 TTR	词汇丰富度	0.974	1.005
仅出现一次词占比	词汇丰富度	0.843	0.839
MATTR-50	词汇丰富度	0.797	0.659
动词 TTR	词汇丰富度	0.727	0.838
名词 TTR	词汇丰富度	0.721	0.535
动词去重词每千字	词汇丰富度	0.713	0.937
Guiraud 值	词汇丰富度	0.656	0.479
非 HSK 词汇种类每千字	HSK	0.644	0.543

表 4-1 词汇丰富度与词汇扩展的主要归属指标。

4.2 D2 基础词汇与叙事推进

该维度的正端由时间词、趋向动词、低等级词汇覆盖和专名推进，负端更多关联中高等级词汇及结构助词。它描述叙事推进所依赖的基础词汇资源与较抽象表达之间的相对配置。

主要正载荷：趋向动词每千字 (0.66) 、1 级词汇种类每千字 (0.60) 、2 级词汇种类每千字 (0.59) 、2 级词汇占比 (0.59) 、1 级词汇占比 (0.54) 、非 HSK 专名每千字 (0.53) 。

主要负载荷：中等词汇占比 (-0.91) 、4 级词汇占比 (-0.73) 、5 级词汇占比 (-0.69) 、结构助词的每千字 (-0.47) 、高等词汇占比 (-0.46) 、6 级词汇占比 (-0.46) 。

字段名	类别	主要载荷	共同度
中等词汇占比	HSK	-0.913	0.906
4 级词汇占比	HSK	-0.730	0.538
5 级词汇占比	HSK	-0.687	0.589
趋向动词每千字	记叙描写	0.661	0.468
1 级词汇种类每千字	HSK	0.604	0.519
2 级词汇种类每千字	HSK	0.594	0.404
2 级词汇占比	HSK	0.592	0.388
1 级词汇占比	HSK	0.545	0.668

表 4-2 基础词汇与叙事推进的主要归属指标。

4.3 D3 人称指涉与信息密度

该维度把代词和人称参与置于正端，把词汇密度、平均词长及部分非 HSK 词汇置于另一端。它主要区分参与者显性指涉与名词化、信息压缩表达，而不是口语和书面语的简单优劣。

主要正载荷：代词每千字 (0.70)、非 HSK 词汇 TTR (0.62)、第三人称代词每千字 (0.59)、第一人称单数代词每千字 (0.57)。

主要负载荷：非 HSK 词汇占比 (-0.74)、平均词长 (-0.52)、词汇密度 (-0.48)。

字段名	类别	主要载荷	共同度
非 HSK 词汇占比	HSK	-0.744	0.674
代词每千字	词性	0.699	0.627
非 HSK 词汇 TTR	HSK	0.625	0.597
第三人称代词每千字	语法标记	0.588	0.349
第一人称单数代词每千字	语法标记	0.569	0.510
平均词长	词汇密度与词长	-0.516	0.465
词汇密度	词汇密度与词长	-0.481	0.359

表 4-3 人称指涉与信息密度的主要归属指标。

4.4 D4 句法延展与分句复杂度

该维度由平均句长、句长变异、长句、逗号和分句数共同定义，反映句子内部展开与从句组织。网页作文可能经过修改或编辑，因此母语参照在该维度上的优势尤其需要结合来源条件解释。

主要正载荷：平均每句分句数 (0.97)、平均句长_字 (0.85)、句长标准差_字 (0.73)、超过 30 字长句每千字 (0.58)、逗号每千字 (0.51)。

字段名	类别	主要载荷	共同度
平均每句分句数	句段结构	0.971	0.956
平均句长_字	句段结构	0.854	0.768
句长标准差_字	句段结构	0.729	0.544
超过 30 字长句每千字	句段结构	0.583	0.370
逗号每千字	句段结构	0.513	0.374

表 4-4 句法延展与分句复杂度的主要归属指标。

4.5 D5 动作过程与动词链

该维度由动词频率、情态动词与连续动词结构构成，反映事件链、动作过程及行动可能性的表达。记叙题通常比议论题更需要动作链，跨题目比较时必须保留任务功能这一前提。

主要正载荷：动词每千字（0.95）、连续动词结构每千字（0.76）、情态动词每千字（0.57）。

字段名	类别	主要载荷	共同度
动词每千字	词性	0.952	0.935
连续动词结构每千字	记叙描写	0.764	0.625
情态动词每千字	语法标记	0.565	0.376

表 4-5 动作过程与动词链的主要归属指标。

因子数	最终变量数	KMO	累计解释方差	统计诊断通过	稳定性通过	诊断说明
2	24	0.733	52.5%	是	是	通过统计诊断
3	32	0.730	51.9%	是	是	通过统计诊断
4	35	0.743	55.2%	是	是	通过统计诊断
5	39	0.752	57.3%	是	是	通过统计诊断
6	48	0.721	55.4%	否	否	出现 Heywood 异常

表 4-6 2 至 6 因子候选模型比较；五因子是通过诊断与稳定性检验的最高维度解。

五因子方案不是由平行分析单独决定，而是平衡统计诊断、Bootstrap 稳定性、每因子至少三个主要载荷和可解释性后的结果。更高维模型虽可提高解释方差，却出现载荷支撑不足或稳定性下降；更低维模型则会把词汇、人称、句法和动作过程压缩到过宽的维度中。

5 学习者四组、分数与国籍

5.1 四组多维画像




图 6 J1、J2、Y1、Y2 的五维得分分布




图 7 四组作文的五维均值画像

维度	J1	J2	Y1	Y2	Omega 平方	BH 校正 p 值
人称指涉与信息密度	1.017	0.168	-1.110	-0.075	0.574	<0.001
动作过程与动词链	-0.099	-0.569	0.735	-0.068	0.216	<0.001
句法延展与分句复杂度	0.182	-0.178	0.132	-0.136	0.020	0.001
基础词汇与叙事推进	0.206	1.008	-0.886	-0.328	0.486	<0.001
词汇丰富度与词汇扩展	0.394	0.411	-0.022	-0.783	0.231	<0.001

表 5 学习者四组五维均值及 Welch 总体效应。维度得分已在学习者样本内标准化。

五个维度的组间 Welch 检验均用于检验四组总体差异，显著结果还需结合两两比较和效应量判断。J1/J2 与 Y1/Y2 的差异同时包含题目和体裁，因此报告使用“题目与体裁组合差异”而不使用纯体裁因果表述。




图 10 学习者四组两两比较的效应量

5.2 作文分数




图 8 作文分数与五维得分趋势

维度名称	Spearman_rho	p 值	BH 校正 p 值
词汇丰富度与词汇扩展	0.037	0.359	0.598
基础词汇与叙事推进	-0.080	0.047	0.118
人称指涉与信息密度	-0.014	0.734	0.803
句法延展与分句复杂度	0.110	0.006	0.030
动作过程与动词链	0.010	0.803	0.803

表 6 作文分数与五维得分的 Spearman 相关。




图 11 分数、题目组和日本籍控制变量的稳健回归系数

5.3 HSK 词汇与维度相关




图 9 学习者四组作文的 HSK 词汇等级构成

初等、中等、高等和非 HSK 词汇构成受题目词汇域显著影响。低等级词汇占比高并不等于语言简单：人物与旅行叙事需要大量基础动作、时间和空间词，而议论题更可能使用抽象名词和中高等级词汇。等级构成必须与 TTR、词汇密度和五维功能共同解释。




图 12 五个斜交维度之间的相关结构

5.4 日本籍与非日本籍补充分析

国籍补充分析仅比较日本籍与非日本籍，并控制题目和分数；不对 42 个国籍进行均值排名。由于日本籍在 J2 中的占比很高，国籍、题目和学习经历并非独立，回归中的国籍系数只能视为探索性控制项。任何显著差异都不能解释为民族或国籍本质属性。

维度	最高组	最低组	Omega 平方	分数 rho	分数 BH 校正 p 值
词汇丰富度与词汇扩展	J2	Y2	0.231	0.037	0.598
基础词汇与叙事推进	J2	Y1	0.486	-0.080	0.118
人称指涉与信息密度	J1	Y1	0.574	-0.014	0.803
句法延展与分句复杂度	J1	J2	0.020	0.110	0.030
动作过程与动词链	Y1	J2	0.216	0.010	0.803

表 7-1 学习者内部证据摘要。最高/最低组按维度均值判定，不代表作文质量排序。

6 公开网络母语参照样本审计

6.1 来源、年级与年份

来源类型	篇数	占比
网络资源	95	52.8%
作文网原创	44	24.4%
作文网	12	6.7%
作文网高中作文文库（作文网原创）	9	5.0%
本站原创	9	5.0%
网络	3	1.7%
E 度作文网原创	2	1.1%
网络转载	2	1.1%
转载	2	1.1%
作文网整理	1	0.6%

表 8 母语样本主表中的来源类型汇总；完整 180 行审计记录仍保留在 Excel。

母语代码	样本量	最早年份	最晚年份	平均汉字数	平均目标偏差	年代扩展样本
NJ1	45	2,009	2,017	508.556	0.305	12
NJ2	45	2,009	2,020	579.444	0.541	16
NY1	45	2,008	2,025	627.822	0.766	21
NY2	45	2,009	2,025	528.444	0.397	12

表 9 母语参照样本的发布年份、篇幅与年代扩展情况。发布日期不等同于实际写作年份。

网站来源标签包括作文网原创、网络资源、本站原创、转载等。标签只用于审计网页自述来源，不验证版权链或作者身份。采集脚本默认单线程、请求间隔 3 至 6 秒，并对 429、403、5xx 和超时进行指数退避；不绕过验证码或访问限制。

6.2 篇幅匹配




图 13 学习者与母语参照作文的篇幅分布及匹配诊断

母语代码	平均汉字数	中位汉字数	平均目标篇幅相对偏差
NJ1	508.556	521.000	0.305
NJ2	579.444	602.000	0.541
NY1	627.822	668.000	0.766
NY2	528.444	540.000	0.397

表 10 母语参照样本篇幅概况。目标篇幅来自对应学习者组的分位点。

公开高中作文整体长于学习者作文。候选选择使用最小总偏差匹配，但网页文章的可用篇幅下界较高，无法实现完全平衡。这一差异可能机械抬高词种数、句法延展和部分篇章组织指标，因此后续同时使用每千字频率、log 篇幅控制和篇幅匹配重抽样。

6.3 主题匹配

180 篇中，精确、近似、扩展和宽泛主题分别为精确 13 篇、近似 10 篇、扩展 50 篇、宽泛 107 篇。宽泛主题主要用于保持高中范围和四组等量，尤其影响 NY1、NY2 和 NJ2。严格主题子样本用于方向敏感性检查，但样本量不足以独立承担显著性检验。

主表提供每篇网页文章的代码、URL、年级、发布日期、来源类型、主题层级、篇幅偏差和正文哈希。
本报告只使用这些字段生成聚合审计信息，不把 180 行清单或网页全文复制进 Word/PDF。

风险	已采取措施	剩余不确定性
作者身份	保留栏目、年级和来源元数据	不能确认作者确为高中母语者
主题偏差	四级主题匹配并做严格主题敏感性	Y1/Y2 严格主题样本很少
篇幅偏差	分位点匹配、每千字频率、HC3 与重抽样	匹配后仍有残余长度差
年代偏差	优先 2005 至 2012 年并标记扩展样本	发布日期不等同于写作年份
重复文本	SHA-256 与字符五元组近重复去重	不能识别所有人工改写版本
编辑加工	不修改正文并记录来源类型	无法判断教师、编辑或平台修改程度

表 10-1 公开网络母语参照语料的主要风险与缓解措施。

7 四组母语参照对照

7.1 五维总体结果




图 14 学习者与母语参照八组作文的五维画像




图 15 四个题目中母语参照减学习者的五维 Hedges g

对应题目	维度	学习者 均值	母语均 值	Hedges_g_母 语减学习者	Hedges_g_Bo otstrap95%CI 下限	Hedges_g_Boot strap95%CI上 限	Holm 校正 p 值
J1	词汇丰富度与词汇扩展	0.394	0.359	-0.036	-0.365	0.319	1.000
J1	基础词汇与叙事推进	0.206	0.011	-0.263	-0.592	0.051	0.609
J1	人称指涉与信息密度	1.017	0.585	-0.595	-0.960	-0.288	0.003
J1	句法延展与分句复杂度	0.182	1.417	0.967	0.634	1.336	<0.001
J1	动作过程与动词链	-0.099	-0.187	-0.100	-0.413	0.216	1.000
J2	词汇丰富度与词汇扩展	0.411	0.394	-0.020	-0.315	0.304	1.000
J2	基础词汇与叙事推进	1.008	0.013	-1.423	-1.838	-1.063	<0.001
J2	人称指涉与信息密度	0.168	0.199	0.044	-0.263	0.352	1.000
J2	句法延展与分句复杂度	-0.178	1.646	1.752	1.407	2.157	<0.001
J2	动作过程与动词链	-0.569	0.170	0.941	0.604	1.331	<0.001
Y1	词汇丰富度与词汇扩展	-0.022	0.442	0.544	0.197	0.909	0.034
Y1	基础词汇与叙事推进	-0.886	-1.416	-0.776	-1.080	-0.492	<0.001
Y1	人称指涉与信息密度	-1.110	-0.866	0.502	0.139	0.902	0.064

对应题目	维度	学习者 均值	母语均 值	Hedges_g_母 语减学习者	Hedges_g_Bo otstrap95%CI 下限	Hedges_g_Boot strap95%CI上 限	Holm 校正 p 值
Y1	句法延展与分句复杂度	0.132	1.430	1.081	0.704	1.497	<0.001
Y1	动作过程与动词链	0.735	0.373	-0.352	-0.659	-0.050	0.208
Y2	词汇丰富度与词汇扩展	-0.783	0.160	1.050	0.706	1.462	<0.001
Y2	基础词汇与叙事推进	-0.328	-1.048	-1.045	-1.354	-0.743	<0.001
Y2	人称指涉与信息密度	-0.075	-0.382	-0.472	-0.770	-0.185	0.026
Y2	句法延展与分句复杂度	-0.136	1.110	1.223	0.885	1.603	<0.001
Y2	动作过程与动词链	-0.068	0.731	0.980	0.678	1.330	<0.001

表 11 四组×五维共 20 项比较；13 项经 Holm 校正后显著。正 g 表示母语参照更高。

7.2 J1/NJ1 人物影响记叙

句法延展与分句复杂度高于学习者（ $g=0.97$ ，大效应，Holm 显著）；人称指涉与信息密度低于学习者（ $g=-0.60$ ，中等效应，Holm 显著）；基础词汇与叙事推进低于学习者（ $g=-0.26$ ，小效应，校正后不显著）；动作过程与动词链低于学习者（ $g=-0.10$ ，可忽略效应，校正后不显著）；词汇丰富度与词汇扩展低于学习者（ $g=-0.04$ ，可忽略效应，校正后不显著）。

具体指标中绝对效应较大的项目为：平均每句分句数（ $g=0.94$ ）、句长标准差_字（ $g=0.94$ ）、1 级词汇种类每千字（ $g=-0.90$ ）、1 级词汇内部 TTR（ $g=-0.84$ ）、逗号每千字（ $g=0.82$ ）、Guiraud 值（ $g=0.77$ ）。

人物影响题应优先从人物指涉、评价资源和事件例证的组织方式解释。公开高中作文可能使用更多修辞和复句资源，但这也可能反映修改机会与网页筛选。

7.3 J2/NJ2 假期旅行及个人经历记叙

句法延展与分句复杂度高于学习者（ $g=1.75$ ，大效应，Holm 显著）；基础词汇与叙事推进低于学习者（ $g=-1.42$ ，大效应，Holm 显著）；动作过程与动词链高于学习者（ $g=0.94$ ，大效应，Holm 显著）；人称指涉与信息密度高于学习者（ $g=0.04$ ，可忽略效应，校正后不显著）；词汇丰富度与词汇扩展低于学习者（ $g=-0.02$ ，可忽略效应，校正后不显著）。

具体指标中绝对效应较大的项目为：平均每句分句数 ($g=1.86$)、高等词汇占比 ($g=1.59$)、1 级词汇种类每千字 ($g=-1.57$)、逗号每千字 ($g=1.57$)、Guiraud 值 ($g=1.55$)、1 级词汇内部 TTR ($g=-1.48$)。

假期与经历题要求时间、地点、趋向和动作序列。叙事推进及动作链是本组最具功能解释力的指标；学习者 J2 中的日本籍比例较高，限制了跨国籍外推。

7.4 Y1/NY1 健康与相邻社会议题

句法延展与分句复杂度高于学习者 ($g=1.08$ ，大效应，Holm 显著)；基础词汇与叙事推进低于学习者 ($g=-0.78$ ，中等效应，Holm 显著)；词汇丰富度与词汇扩展高于学习者 ($g=0.54$ ，中等效应，Holm 显著)；人称指涉与信息密度高于学习者 ($g=0.50$ ，中等效应，校正后不显著)；动作过程与动词链低于学习者 ($g=-0.35$ ，小效应，校正后不显著)。

具体指标中绝对效应较大的项目为：高等词汇占比 ($g=2.74$)、Guiraud 值 ($g=2.55$)、非 HSK 词汇 TTR ($g=1.82$)、非 HSK 专名每千字 ($g=1.46$)、1 级词汇种类每千字 ($g=-1.36$)、平均每句分句数 ($g=1.18$)。

Y1 精确网页样本最少，大量参照文章来自健康行为与相邻社会议题。全样本差异必须与严格主题子样本方向一起阅读，不能视为严格同题结果。

7.5 Y2/NY2 父母教育与成长议题

句法延展与分句复杂度高于学习者 ($g=1.22$ ，大效应，Holm 显著)；词汇丰富度与词汇扩展高于学习者 ($g=1.05$ ，大效应，Holm 显著)；基础词汇与叙事推进低于学习者 ($g=-1.05$ ，大效应，Holm 显著)；动作过程与动词链高于学习者 ($g=0.98$ ，大效应，Holm 显著)；人称指涉与信息密度低于学习者 ($g=-0.47$ ，小效应，Holm 显著)。

具体指标中绝对效应较大的项目为：Guiraud 值 ($g=1.98$)、名词 TTR ($g=1.67$)、6 级词汇占比 ($g=1.67$)、非 HSK 词汇种类每千字 ($g=1.62$)、逗号每千字 ($g=1.59$)、1 级词汇占比 ($g=-1.54$)。

Y2 参照范围扩展至家风、责任、成长和教育方式。网页作文可能带有模板化议论结构，因此连接、词汇等级和句法差异都需结合来源条件解释。

7.6 具体语言特征




图 16 四组母语对照中绝对效应最大的具体语言特征

对应题目	字段名	所属维度	学习者均值	母语均值	Hedges_g_母语减学习者	BH 校正 p 值
Y1	高等词汇占比	基础词汇与叙事推进	0.021	0.067	2.740	<0.001
Y1	Guiraud 值	词汇丰富度与词汇扩展	8.493	11.024	2.554	<0.001
Y2	Guiraud 值	词汇丰富度与词汇扩展	8.136	9.993	1.984	<0.001
J2	平均每句分句数	句法延展与分句复杂度	2.380	3.767	1.860	<0.001
Y1	非 HSK 词汇 TTR	人称指涉与信息密度	0.548	0.730	1.823	<0.001
Y2	名词 TTR	词汇丰富度与词汇扩展	0.495	0.681	1.675	<0.001

对应题目	字段名	所属维度	学习者均值	母语均值	Hedges_g_母语减学习者	BH 校正 p 值
Y2	6 级词汇占比	基础词汇与叙事推进	0.020	0.044	1.671	<0.001
Y2	非 HSK 词汇种类每千字	词汇丰富度与词汇扩展	46.659	72.741	1.617	<0.001
Y2	逗号每千字	句法延展与分句复杂度	45.912	67.466	1.593	<0.001
J2	高等词汇占比	基础词汇与叙事推进	0.017	0.043	1.588	<0.001
J2	1 级词汇种类每千字	基础词汇与叙事推进	122.115	88.270	-1.574	<0.001
J2	逗号每千字	句法延展与分句复杂度	54.130	76.059	1.567	<0.001
J2	Guiraud 值	词汇丰富度与词汇扩展	8.992	10.582	1.548	<0.001
Y2	1 级词汇占比	基础词汇与叙事推进	0.471	0.383	-1.540	<0.001
Y2	动词每千字	动作过程与动词链	156.411	185.803	1.536	<0.001
Y2	高等词汇占比	基础词汇与叙事推进	0.027	0.052	1.492	<0.001
J2	1 级词汇内部 TTR	词汇丰富度与词汇扩展	0.379	0.299	-1.478	<0.001
Y2	非 HSK 词汇占比	人称指涉与信息密度	0.099	0.141	1.461	<0.001
Y1	非 HSK 专名每千字	基础词汇与叙事推进	1.247	7.435	1.457	<0.001
J2	句长标准差_字	句法延展与分句复杂度	11.596	22.148	1.410	<0.001

表 12 39 项固定投影特征中绝对效应最大的 20 项；BH 校正 在 156 项比较内执行。

7.7 HSK 词汇构成




图 17 学习者与母语参照的 HSK 初中高及非 HSK 词汇构成

代码	初等词汇占比	中等词汇占比	高等词汇占比	非 HSK 词汇占比	HSK 词汇覆盖率
J1	67.9%	17.9%	2.9%	11.2%	88.8%
NJ1	64.9%	17.0%	4.1%	13.9%	86.1%
J2	69.3%	15.3%	1.7%	13.7%	86.3%
NJ2	63.5%	18.6%	4.3%	13.6%	86.4%

代码	初等词汇占比	中等词汇占比	高等词汇占比	非 HSK 词汇占比	HSK 词汇覆盖率
Y1	55.7%	25.5%	2.1%	16.7%	83.3%
NY1	49.7%	27.2%	6.7%	16.3%	83.7%
Y2	66.4%	21.0%	2.7%	9.9%	90.1%
NY2	55.3%	25.4%	5.2%	14.1%	85.9%

表 13 八组作文 HSK 词汇构成均值。所有比例的分母均为非标点分词数。

母语参照中的非 HSK 词汇包含专名、成语、新词、词表外表达和分词误差，不能直接标记为高级词。学习者与参照作文的 HSK 构成差异还受到题目词汇域影响，因此报告不使用单一覆盖率评价语言水平。

指标	回答问题	解释限制
HSK 覆盖率	命中 11,000 条词表的 token 比例	受专名、新词和分词影响
高等词汇占比	7 至 9 级词汇占全部非标点 token 比例	题目域可能机械抬高或压低
等级内部 TTR	某等级词种数 ÷ 该等级 token 数	低频等级样本过少时波动大
非 HSK 词汇占比	未命中词表的 token 比例	不能直接解释为错误或高级词
非 HSK 专名	未命中词表且被识别为专名	人物与地点题更容易出现

表 13-1 HSK 派生指标的解释边界。

8 稳健性与联合因子分析

8.1 篇幅匹配重抽样




图 18 1000 次篇幅匹配重抽样的五维均值差

对应题目	维度	重抽样均值差	重抽样标准差	篇幅均值差	重抽样 95%CI 下限	重抽样 95%CI 上限
J1	人称指涉与信息密度	-0.200	0.027	40.216	-0.252	-0.143
J1	动作过程与动词链	-0.322	0.042	40.216	-0.405	-0.245
J1	句法延展与分句复杂度	0.849	0.062	40.216	0.730	0.965
J1	基础词汇与叙事推进	-0.040	0.029	40.216	-0.097	0.013
J1	词汇丰富度与词汇扩展	-0.213	0.043	40.216	-0.296	-0.136
J2	人称指涉与信息密度	0.023	0.028	118.755	-0.022	0.066
J2	动作过程与动词链	0.736	0.027	118.755	0.704	0.769
J2	句法延展与分句复杂度	1.693	0.025	118.755	1.654	1.731

对应题目	维度	重抽样均值差	重抽样标准差	篇幅均值差	重抽样 95%CI 下限	重抽样 95%CI 上限
J2	基础词汇与叙事推进	-0.835	0.027	118.755	-0.873	-0.796
J2	词汇丰富度与词汇扩展	0.121	0.037	118.755	0.060	0.182
Y1	人称指涉与信息密度	0.180	0.000	192.333	0.180	0.180
Y1	动作过程与动词链	-0.461	0.000	192.333	-0.461	-0.461
Y1	句法延展与分句复杂度	1.159	0.000	192.333	1.159	1.159
Y1	基础词汇与叙事推进	-0.499	0.000	192.333	-0.499	-0.499
Y1	词汇丰富度与词汇扩展	0.688	0.000	192.333	0.688	0.688
Y2	人称指涉与信息密度	-0.378	0.029	78.823	-0.432	-0.324
Y2	动作过程与动词链	0.637	0.041	78.823	0.558	0.706
Y2	句法延展与分句复杂度	1.291	0.047	78.823	1.198	1.378
Y2	基础词汇与叙事推进	-0.802	0.027	78.823	-0.851	-0.749
Y2	词汇丰富度与词汇扩展	1.145	0.027	78.823	1.095	1.196

表 14 篇幅最近邻重抽样；18/20 项 95%区间不跨 0。

匹配后的母语参照相对学习者平均残余篇幅差为 J1 40.2 字、J2 118.8 字、Y1 192.3 字、Y2 78.8 字。Y1 残差最大，说明重抽样降低但没有消除篇幅混杂。

8.2 主题、年份与 HC3 回归

敏感性样本	比较项	平均绝对差
2005 至 2012 年	20	0.587
全部母语样本	20	0.625
精确或近似主题	20	0.947

表 15 全样本、严格主题和优先年份敏感性分析概况。

精确或近似主题子样本量为 J1=9、J2=8、Y1=2、Y2=4。Y1 和 Y2 样本量过小，只能用于方向检查。控制 log 篇幅的 HC3 模型进一步检验来源主效应及来源×题目交互，但仍无法控制作者背景、修改次数和编辑加工。

维度	项	系数	HC3 标准误	95%CI 下限	95%CI 上限	BH 校正 p 值
词汇丰富度与词汇扩展	语料来源：母语参照 (J1)	0.212	0.169	-0.119	0.543	0.269
词汇丰富度与词汇扩展	语料来源×J2	0.169	0.214	-0.251	0.589	0.496
词汇丰富度与词汇扩展	语料来源×Y1	0.779	0.233	0.322	1.235	0.002
词汇丰富度与词汇扩展	语料来源×Y2	1.006	0.231	0.553	1.459	<0.001
基础词汇与叙事推进	语料来源：母语参照 (J1)	-0.131	0.126	-0.379	0.117	0.365
基础词汇与叙事推进	语料来源×J2	-0.760	0.173	-1.099	-0.422	<0.001
基础词汇与叙事推进	语料来源×Y1	-0.262	0.161	-0.577	0.054	0.147
基础词汇与叙事推进	语料来源×Y2	-0.517	0.165	-0.841	-0.194	0.004

维度	项	系数	HC3 标准 误	95%CI 下 限	95%CI 上 限	BH 校正 p 值
人称指涉与信息密度	语料来源：母语参照 (J1)	-0.423	0.117	-0.651	-0.194	<0.001
人称指涉与信息密度	语料来源×J2	0.468	0.160	0.154	0.782	0.007
人称指涉与信息密度	语料来源×Y1	0.687	0.152	0.389	0.985	<0.001
人称指涉与信息密度	语料来源×Y2	0.126	0.153	-0.173	0.426	0.483
句法延展与分句复杂度	语料来源：母语参照 (J1)	1.090	0.277	0.546	1.633	<0.001
句法延展与分句复杂度	语料来源×J2	0.500	0.383	-0.251	1.251	0.254
句法延展与分句复杂度	语料来源×Y1	-0.102	0.387	-0.861	0.658	0.849
句法延展与分句复杂度	语料来源×Y2	-0.007	0.349	-0.692	0.678	0.984
动作过程与动词链	语料来源：母语参照 (J1)	-0.177	0.152	-0.475	0.120	0.304
动作过程与动词链	语料来源×J2	0.773	0.204	0.374	1.172	<0.001
动作过程与动词链	语料来源×Y1	-0.376	0.237	-0.840	0.089	0.154
动作过程与动词链	语料来源×Y2	0.876	0.202	0.481	1.272	<0.001

表 16 HC3 模型中的语料来源主效应和题目交互项。

8.3 联合因子结构

因子数	变量数	KMO	累计解释方差	诊断通过	稳定性通 过	最小 Tucker 中位数	诊断说明
2	24	0.735	50.8%	是	是	0.999	通过统计诊断
3	32	0.751	52.3%	否	否	0.000	出现 Heywood 异常
4	37	0.747	54.7%	否	否	0.000	出现 Heywood 异常
5	46	0.731	53.4%	否	否	0.000	出现 Heywood 异常
6	49	0.737	56.3%	否	否	0.000	出现 Heywood 异常
7	49	0.736	60.3%	否	否	0.000	出现 Heywood 异常
8	50	0.723	63.4%	否	否	0.000	出现 Heywood 异常
9	52	0.743	63.2%	否	否	0.000	出现 Heywood 异常
10	54	0.746	66.8%	否	否	0.000	存在少于 3 个主要载荷的因子；出现 Heywood 异常

表 17 800 篇作文联合 EFA 候选模型诊断。




图 19 学习者五维与 800 篇联合模型的 Tucker 一致性

联合平行分析建议 14 个因子，但 2 至 10 因子候选中只有 2 因子方案同时通过预设诊断和稳定性要求。该方案保留 24 项指标，KMO=0.735；与原五维的已匹配 Tucker 一致性最小值为 0.81。因此联合结构不能完整复现原五维，固定五维投影适合描述差异，却不证明五维在两种语料来源中具有完全相同的潜在结构。

项目		固定五维投影	联合 EFA
参数来源	仅 620 篇学习者作文	全部 800 篇作文	
主要目的	保持原五维量尺并比较来源	检查新增语料是否改变共现结构	
维度数量	固定 5 维	通过诊断的方案为 2 维	
结果地位	母语比较的主分析	结构迁移的敏感性分析	
可解释结论	同一量尺上的组间位置	原五维能否跨来源完整重复	

表 17-1 固定投影与联合因子分析承担的不同任务。

9 五维综合证据

维度	学习者最高/最低	分数 rho	最强母语对照	Holm 显著组数	篇幅重抽样稳定组数
词汇丰富度与词汇扩展	J2 / Y2	0.037	Y2 g=1.05	2	4
基础词汇与叙事推进	J2 / Y1	-0.080	J2 g=-1.42	3	3
人称指涉与信息密度	J1 / Y1	-0.014	J1 g=-0.60	2	3
句法延展与分句复杂度	J1 / J2	0.110	J2 g=1.75	4	4
动作过程与动词链	Y1 / J2	0.010	Y2 g=0.98	2	4

表 18 学习者内部、分数关系和母语对照的五维证据汇总。

综合表把三类问题放在同一行：学习者组间位置、与分数的单调关系、母语参照的最大来源差异，以及篇幅重抽样后的稳定性。这些证据回答的是不同层级的问题，不能用一个显著结果替代另一个。例如，某维度与分数相关，并不意味着该维度上的母语参照方向就是评分标准。

9.1 词汇丰富度与词汇扩展

学习者内部均值最高组为 J2 (0.41)，最低组为 Y2 (-0.78)。与分数的 Spearman 相关为 $\rho=0.04$ (BH 校正后 $p=0.598$)。母语参照最大差异出现在 Y2， $g=1.05$ ，Bootstrap 95%CI [0.71, 1.46]。Holm 显著的题目为 Y1、Y2。

该维度集中反映词形多样性、篇内低重复程度以及名词和动词词库的扩展。高分表示同等篇幅内动用的不同词形较多，不等同于词语更生僻，也不能单独代表作文质量。

9.2 基础词汇与叙事推进

学习者内部均值最高组为 J2 (1.01)，最低组为 Y1 (-0.89)。与分数的 Spearman 相关为 $\rho=-0.08$ (BH 校正后 $p=0.118$)。母语参照最大差异出现在 J2， $g=-1.42$ ，Bootstrap 95%CI [-1.84, -1.06]。Holm 显著的题目为 J2、Y1、Y2。

该维度的正端由时间词、趋向动词、低等级词汇覆盖和专名推进，负端更多关联中高等级词汇及结构助词。它描述叙事推进所依赖的基础词汇资源与较抽象表达之间的相对配置。

9.3 人称指涉与信息密度

学习者内部均值最高组为 J1 (1.02) ，最低组为 Y1 (-1.11) 。与分数的 Spearman 相关为 $\rho=-0.01$ (BH 校正后 $p=0.803$) 。母语参照最大差异出现在 J1 ， $g=-0.60$ ，Bootstrap 95%CI [-0.96, -0.29]。Holm 显著的题目为 J1、Y2。

该维度把代词和人称参与置于正端，把词汇密度、平均词长及部分非 HSK 词汇置于另一端。它主要区分参与者显性指涉与名词化、信息压缩表达，而不是口语和书面语的简单优劣。

9.4 句法延展与分句复杂度

学习者内部均值最高组为 J1 (0.18) ，最低组为 J2 (-0.18) 。与分数的 Spearman 相关为 $\rho=0.11$ (BH 校正后 $p=0.030$) 。母语参照最大差异出现在 J2 ， $g=1.75$ ，Bootstrap 95%CI [1.41, 2.16]。Holm 显著的题目为 J1、J2、Y1、Y2。

该维度由平均句长、句长变异、长句、逗号和分句数共同定义，反映句子内部展开与从句组织。网页作文可能经过修改或编辑，因此母语参照在该维度上的优势尤其需要结合来源条件解释。

9.5 动作过程与动词链

学习者内部均值最高组为 Y1 (0.74) ，最低组为 J2 (-0.57) 。与分数的 Spearman 相关为 $\rho=0.01$ (BH 校正后 $p=0.803$) 。母语参照最大差异出现在 Y2 ， $g=0.98$ ，Bootstrap 95%CI [0.68, 1.33]。Holm 显著的题目为 J2、Y2。

该维度由动词频率、情态动词与连续动词结构构成，反映事件链、动作过程及行动可能性的表达。记叙题通常比议论题更需要动作链，跨题目比较时必须保留任务功能这一前提。

9.6 与参考文献的关系

项目	徐勤 2021	徐勤 2023 博士论文	本报告
样本	日本学习者与母语者叙述文	多体裁学习者与母语者作文	620 篇 HSK 作文+180 篇公开网页参照
主要方法	MF/MD 因子分析	MF/MD 与多体裁比较	学习者 EFA、固定投影、稳健检验、联合 EFA
共同维度	语句复杂性、动作描写	词汇产出、动作描写等	词汇丰富、句法延展、动作过程

项目	徐勤 2021	徐勤 2023 博士论文	本报告
本项目特有	单一叙述任务	多体裁任务	基础词汇推进、人称指涉及 HSK 等级
关键限制	学习者背景集中	任务与体裁混合	网页身份、主题扩展与篇幅不平衡

表 19 两篇参考论文与本综合报告的方法关系。

词汇丰富、句法延展和动作过程与参考研究有较清晰概念对应，基础词汇推进与人称指涉则更受本项目题目设计和 HSK 指标体系影响。这说明多维分析既能识别跨研究重复的功能成分，也会形成语料特定维度；维度命名必须依赖当前载荷而不能直接套用前人标签。

证据等级	判定条件	报告用途
优先级 1	效应量区间、校正 p 值、重抽样和主题敏感性方向一致	可进入人工文本复核
优先级 2	主比较显著，但篇幅或严格主题结果不稳定	保留结论并明确条件
优先级 3	只有未经校正 p 值或单一描述指标支持	作为探索线索，不写作主结论
不作推断	来源身份、编辑过程或写作条件无法核验	不得转写为母语能力因果差异

表 19-1 综合结论的证据优先级。

10 教学与研究启示

按题目功能组织教学。人物题需要指涉与评价，经历题需要时间、趋向和动作链，议论题需要抽象词汇、分句与逻辑关系。统一要求所有作文提高同一指标，容易偏离任务。

把多维画像用于诊断。反馈可以分别指出词汇重复、人称过密、长句失控或动作链不足，而不把单一总分当作全部语言表现。维度高低应转化为可观察的语言选择。

词汇等级与丰富度联合解释。HSK 高等级占比、非 HSK 覆盖、MATTR 和词汇密度分别回答不同问题。词汇等级高不保证篇内多样，非 HSK 多也不自动等于高级表达。

优先复核多重证据一致的大效应。同时通过 Holm/BH 校正、Bootstrap、篇幅重抽样和主题敏感性的指标，适合作为后续人工文本分析与教学干预候选。

建立同题、可核验的母语语料。下一轮应让身份和年级可核验的高中生在相同题目、时间限制和修改条件下写作，以区分语言背景、网页编辑与任务条件。

保留模型的可复现链条。从清洗、分词、特征词表、301 列宽表到 39 项因子模型均应版本化；新增语料时先固定投影，再把重新提取的因子结构作为敏感性分析。

11 局限

- 作文网栏目归类不能认证作者身份，也不能排除编辑、转载、润色或教师示例；来源差异不能直接解释为母语能力。
- NJ2、NY1 和 NY2 为保持每组 45 篇而使用大量宽泛主题，尤其 NY1 严格主题样本极少；这些组更接近相邻题目域参照。
- 母语参照整体长于学习者作文，最近邻匹配后仍存在残余篇幅差；每千字频率、HC3 回归和重抽样只能部分缓解。
- 两类语料的写作时间、修改机会、受众、是否使用资料和评分条件不同，来源变量混合了多种未观测情境。

- 学习者作文没有 75 分层级，国籍样本量不均，日本籍与 J2 高度相关，限制了分数与国籍分析的外推。
- PyNLPIR 会对专名、成语、新词和细粒度词性产生误差；共同处理口径支持相对比较，但不能保证每个 token 绝对正确。
- HSK 词表中的非命中项不等于错误或高级词，同形多等级词的最低等级回退也会影响边界词统计。
- 探索性因子分析依赖样本与指标集合；联合 800 篇语料只得到稳定的 2 因子方案，原五维不是跨来源完全不变的测量模型。
- 统计显著不等于教学重要，效应量也不能替代具体文本功能；所有结论都需要人工语篇分析复核。
- 网页全文因服务协议只在本地保存，公开仓库无法提供完全自足的文本复核包。

12 结论

本项目已经形成从 620 篇 HSK 学习者作文到 180 篇公开网络高中作文参照的统一分析链。301 列宽表提供细粒度语言描述，39 项最终指标把共同变异压缩为词汇丰富度与词汇扩展、基础词汇与叙事推进、人称指涉与信息密度、句法延展与分句复杂度、动作过程与动词链五个维度。学习者内部的题目组、分数和补充国籍分析与母语参照投影共同表明，作文语言差异是多方向的资源配置，而不是单一复杂度阶梯。

四组母语对照的 20 项维度比较中有 13 项经 Holm 校正后显著，18 项在篇幅匹配重抽样中保持方向稳定。但宽泛主题、残余篇幅差和网页来源不确定性要求降低因果表述。联合因子分析未完整复制原五维，更进一步说明固定投影适合比较，不能替代独立验证。现阶段最合理的用途，是利用综合证据筛选值得人工复核和严格同题实验复现的语言特征。

参考文献与网页来源

徐勤（2021）. 日本人中国語学習者の叙述文における言語的特徴の分析：MF/MD 法を使って．《言語文化共同研究プロジェクト》2020，27-41．<https://doi.org/10.18910/85007>

徐勤 (2023) . 中国語作文における言語特徴の考察：多次元分析による日本人中国語学習者と中国語母語話者の作文の比較 . 大阪大学博士学位論文 . <https://doi.org/10.18910/91825>

Biber, D. (1988). Variation Across Speech and Writing. Cambridge University Press.

中华人民共和国教育部、国家语言文字工作委员会 (2021) . 《国际中文教育中文水平等级标准》 (GF 0025—2021) 。

新版 HSK 考试大纲词汇表：项目文件《新版 HSK 考试大纲 1219.pdf》及机器可读《新版 HSK 词汇大纲.csv》。

作文网高中作文栏目：<https://www.zuowen.com/gaozhong/>。

作文网服务协议：<http://www.zuowen.com/help/agreement/>。

附录 A 最终因子载荷

字段名	所属维度	主要载荷	共同度	正负极
词形丰富度 TTR	词汇丰富度与词汇扩展	0.974	1.005	正向
仅出现一次词占比	词汇丰富度与词汇扩展	0.843	0.839	正向
MATTR-50	词汇丰富度与词汇扩展	0.797	0.659	正向
动词 TTR	词汇丰富度与词汇扩展	0.727	0.838	正向
名词 TTR	词汇丰富度与词汇扩展	0.721	0.535	正向
动词去重词每千字	词汇丰富度与词汇扩展	0.713	0.937	正向
Guiraud 值	词汇丰富度与词汇扩展	0.656	0.479	正向
非 HSK 词汇种类每千字	词汇丰富度与词汇扩展	0.644	0.543	正向
名词去重词每千字	词汇丰富度与词汇扩展	0.634	0.507	正向
1 级词汇内部 TTR	词汇丰富度与词汇扩展	0.596	0.510	正向
4 级词汇内部 TTR	词汇丰富度与词汇扩展	0.508	0.398	正向
中等词汇占比	基础词汇与叙事推进	-0.913	0.906	负向
4 级词汇占比	基础词汇与叙事推进	-0.730	0.538	负向
5 级词汇占比	基础词汇与叙事推进	-0.687	0.589	负向
趋向动词每千字	基础词汇与叙事推进	0.661	0.468	正向
1 级词汇种类每千字	基础词汇与叙事推进	0.604	0.519	正向
2 级词汇种类每千字	基础词汇与叙事推进	0.594	0.404	正向
2 级词汇占比	基础词汇与叙事推进	0.592	0.388	正向
1 级词汇占比	基础词汇与叙事推进	0.545	0.668	正向
非 HSK 专名每千字	基础词汇与叙事推进	0.528	0.581	正向
时间词每千字	基础词汇与叙事推进	0.478	0.321	正向
结构助词的每千字	基础词汇与叙事推进	-0.471	0.430	负向
高等词汇占比	基础词汇与叙事推进	-0.460	0.408	负向
6 级词汇占比	基础词汇与叙事推进	-0.457	0.365	负向
非 HSK 词汇占比	人称指涉与信息密度	-0.744	0.674	负向
代词每千字	人称指涉与信息密度	0.699	0.627	正向
非 HSK 词汇 TTR	人称指涉与信息密度	0.625	0.597	正向
第三人称代词每千字	人称指涉与信息密度	0.588	0.349	正向
第一人称单数代词每千字	人称指涉与信息密度	0.569	0.510	正向
平均词长	人称指涉与信息密度	-0.516	0.465	负向
词汇密度	人称指涉与信息密度	-0.481	0.359	负向
平均每句分句数	句法延展与分句复杂度	0.971	0.956	正向
平均句长_字	句法延展与分句复杂度	0.854	0.768	正向
句长标准差_字	句法延展与分句复杂度	0.729	0.544	正向
超过 30 字长句每千字	句法延展与分句复杂度	0.583	0.370	正向
逗号每千字	句法延展与分句复杂度	0.513	0.374	正向
动词每千字	动作过程与动词链	0.952	0.935	正向
连续动词结构每千字	动作过程与动词链	0.764	0.625	正向
情态动词每千字	动作过程与动词链	0.565	0.376	正向

表 A1 最终 39 项指标的主要维度归属。完整五维交叉载荷见《作文多维分析结果.xlsx》。

附录 B 母语样本审计摘要

母语代码	样本量	精确主题	近似主题	扩展主题	宽泛主题	最早年份	最晚年份	年代扩展样本
NJ1	45	4	5	36	0	2,009	2,017	12
NJ2	45	4	4	3	34	2,009	2,020	16
NY1	45	2	0	1	42	2,008	2,025	21
NY2	45	3	1	10	31	2,009	2,025	12

表 B1 四组母语参照样本的主题与年份审计。完整逐篇记录见《母语作文样本主表.xlsx》。

来源类型	篇数	占比
网络资源	95	52.8%
作文网原创	44	24.4%
作文网	12	6.7%
作文网高中作文文库（作文网原创）	9	5.0%
本站原创	9	5.0%
网络	3	1.7%
E 度作文网原创	2	1.1%
网络转载	2	1.1%
转载	2	1.1%
作文网整理	1	0.6%
百度文库	1	0.6%

表 B2 母语参照样本来源类型汇总。

附录 C 可复现性说明

项目	取值
学习者 MF/MD 随机种子	20,260,829
学习者平行分析次数	1,000
学习者 Bootstrap 成功次数	200
母语分析随机种子	20,260,830
母语比较 Bootstrap 次数	2,000
篇幅匹配重抽样次数	1,000
联合平行分析次数	1,000
联合 Bootstrap 次数	200

表 C1 两阶段分析的固定随机参数。

复现顺序：先运行 segment_hsk_clean_texts.py 生成学习者宽表；运行 analyze_composition_mfmd.py 及其工作簿、报告脚本；再运行

collect_zuowen_native_controls.py、segment_native_control_texts.py、analyze_native_control.py 及其工作簿、报告脚本；最后运行 build_integrated_composition_report.py。综合脚本只读取两阶段正式结果，不重估因子或改变样本。

主要结果文件包括《作文词性统计宽表.xlsx》《作文多维分析结果.xlsx》《母语作文样本主表.xlsx》《母语作文词性统计宽表.xlsx》和《作文母语对照分析结果.xlsx》。完整网页正文及缓存不进入 Git，报告中的所有采样数字均可由母语样本主表重新汇总。